# Statistiques Fonctionnelles

CARLU Jonas, AFANE Fouad, LANCON Cindy

2026-02-24

## Introduction

Ce projet a pour objectif d'étudier les profils de consommation électrique de $n = 6\,291$ entreprises, observées sur $D = 672$ instants de mesure espacés de 30 minutes sur deux semaines consécutives. On note i = 1,. . . ,n, l'indice d'une entreprise et $t \in [1, 672]$ l'instant de mesure.

Les données présentent plusieurs propriétés qui justifient une approche par statistiques fonctionnelles :

- **Continuité** : les profils de consommations observés $Y_i(t)$ sont des discrétisations d'une fonction continue sous-jacente.
- **Ordre** : l'intervalle temporel [1,672] est ordonnée et muni d'une distance : l'instant $t_{10}$ arrive necessairement après $t_9$, ce qui distinque les données fonctionnelles d'un simple vecteur de variables.
- **Cohérence** : les courbes sont toutes définies sur le même domaine, à la même échalle et avec la même interprétation pour toutes les entreprises i et tous les instants t.
- **Régularité** : la fonction $f_i$ est supposée suffisamment lisse et ne varie pas brutalement pour des petites variations de t.
- **Colocalisation** : chaque instant $t$ a la même interprétation pour toutes les entreprises. Par exemple, t=48 correspond toujours à la fin du premier jour pour tous les individus.

Ces propriétés nous amènent à considérer chaque ligne du jeu de données non pas comme un vecteur de $\mathbb{R}^D$, mais comme la discrétisation d'une fonction de consommation évoluant dans le temps. Nous adaptons donc une approche de Statistiques Fonctionnelles (FDA). L'analyse reposera sur trois étapes principales :

- Reconstruction des courbes continues par lissage B-splines pénalisé.
- Mise en oeuvre d'une Analyse en Composantes Principales Fonctionnelle (ACP fonctionnelle), afin de résumer la variabilité des courbes et d'identifier les principaux modes de variation des profils de consommation.
- Classification des entreprises par clustering, afin de regrouper les consommateurs présentant des comportements similaires.

```r
#Chargement des données
chemin <- "donnees/smart278co.Rdata"
load(chemin)
table <- smart.278co
df <- as.data.frame(table)

#Nb de lignes
n <- nrow(table)
```

```r
#Nb de cols
p <- ncol(table)
#indices des mesures
time <- 1:p
```

### Packages utilisés

- ***fda*** : package permettant la manipulation et création d'objets fonctionnels (fd), le lissage B-splines pénalisé (smooth.basis, fdPar) et l'ACP fonctionnelle (pca.fd).
- ***refund*** : package dédié aux méthodes de regression fonctionnelle, il fournit notamment l'algorithme FACE (fpca.face) qui estime l'opérateur de covariance par lissage direct, très efficace sur grands jeux de données.
- ***mgcv*** : package de modélisation par splines pénalisées, permet d'ajuster des modèles additifs (gam).
- ***lme4*** : package de modèles mixtes, utilisé ici pour ajuster des modèles de Poisson locaux (glmer) dans le cadre de l'approche GFPCA.
- ***cluster*** et ***factoextra*** : ces deux packages sont utilisés pour le clustering. Le premier fournit les algorithmes de classification et le deuxième permet la visualisation des résultats.
- ***ggplot2, tidyr, dplyr*** : packages utilisés pour la manipulation et visualisation des données.

## Exploration des données

Avant toute modélisation, on peut représenter des exemples des données brutes :

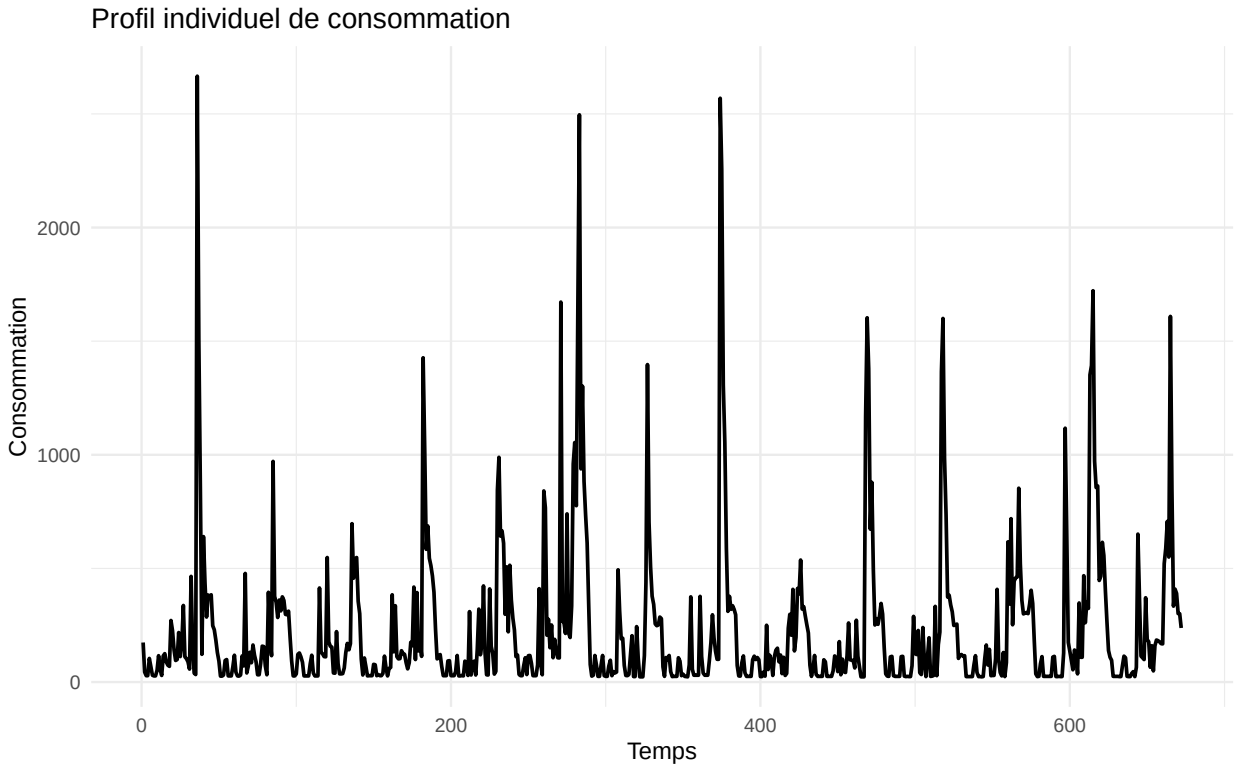

Les profils présentent une structure périodique marquée correspondant aux cycles journaliers. On observe des pics de consommation récurrents, probablement liés aux usages domestiques (matin, soir, weekends), ainsi qu'une variabilité notable entre individus.

Afin de synthétiser cette information, nous calculons ensuite la courbe moyenne et la courbe médiane, plus robuste aux profils atypiques.

**Remarque** : La médiane calculée ici est une médiane point par point, elle est calculée indépendamment à chaque instant t. Elle ne tient pas compte de la structure globale des courbes. Une alternative plus rigoureuse est la médiane géométrique fonctionnelle, qui peut être calculé grâce à la fonction median.fd(.) du package fda.

```
#Courbe moyenne et mediane
f_mean <- colMeans(table,  na.rm=T)
f_median <- apply(table, 2, median, na.rm=T)
```

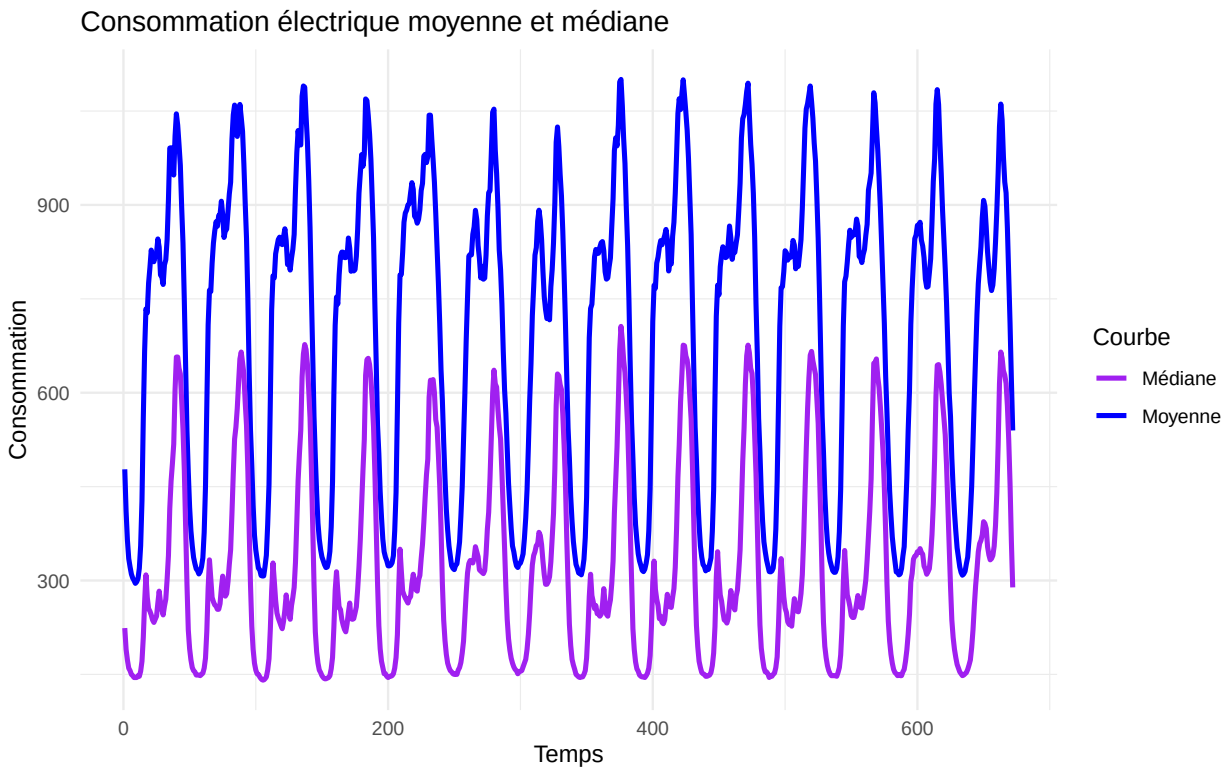


La courbe moyenne met clairement en évidence une structure périodique régulière.On observe clairement quatorze cycles journaliers successifs. Chaque cycle présente une dynamique similaire : une phase de faible consommation nocturne suivie de pics plus marqués en journée, probablement associés aux usages domestiques (chauffage, cuisson, éclairage).

La stabilité de la forme moyenne suggère que la variabilité observée entre individus porte principalement sur l'amplitude des pics plutôt que sur la structure temporelle globale.

On observe aussi un écart important entre la courbe moyenne et la courbe médiane, la moyenne est environ 2 à 3 fois plus élevée que la médiane. Cela indique déjà la présence d'entreprises avec une consommation très élevée qui font augmenter la moyenne.

# Vérification des valeurs manquantes

```r
sum(is.na(table))
```

```
## [1] 0
```

Aucune valeur manquante n'est détectée dans la matrice de données. Il n'est donc pas nécessaire d'effectuer une étape d'imputation ou de reconstruction préalable.

# Lissage semi-paramétrique

L'objectif de cette partie est de passer des observations discrètes $Y_i$ à des courbes continues $\hat{f}_i$, afin de pouvoir appliquer par la suite l'ACP fonctionnelle et le clustering.

Pour réaliser cette transformation, nous utilisons dans les deux cas un lissage par B-splines pénalisées. Les deux approches reposent sur la même pénalisation mais diffèrent dans la méthode de sélection du paramètre de lissage $\delta$ : par validation croisée généralisée (GCV) pour la première, et par la méthode REML (Restricted Maximum Likelihood) pour la seconde.

## Alternative 1 : Base de B-splines et Validation Croisée

Les données de consommation de chaque entreprise i sont observées aux instants discrétisés $t_1, ..., t_D$, avec D= 672 points qui sont équidistants espacés de 30 minutes sur deux semaines.

L'objectif de cette partie est donc de passer des observations discrètes et bruitées $Y_i$, aux véritables courbes continues $\hat{f}_i$. En effet, les données brutes comportent du bruit de mesure qui empêche de comparer les individus point par point.

Pour chaque entreprise i, on pose le modèle :

$$Y_i(t_d) = f_i(t_d) + \epsilon_i(t_d), d = 1, ..., D$$

où $\epsilon_i$ est le bruit et $f_i$ est estimée dans une base de B-splines $B_1(.), ...., B_q(.)$, de dimension q = K+m, avec :

- K = nombre de noeuds intérieurs équidistants sur [1 : 672]
- m-1 = degré des polynômes par morceaux.

L'estimation de la courbe s'écrit donc :

$$\hat{f}_i(t) = \sum_{k=1}^{q} \hat{\beta}_k B_k(t)$$

Les coefficients $\beta = (\beta_1, ..., \beta_q)^T$ sont estimés en minimisant l'erreur quadratique pénalisée :

$$\sum_{d=1}^{D} \left(Y_i(t_d) - f_i(t_d)\right)^2 \; + \; \delta \int \left(f_i''(t)\right)^2 dt$$

où :

- $\delta \geq 0$ est le paramètre de lissage.
  - Si $\delta \to 0$, la pénalisation est nulle et le courbe risque de sur-ajuster.
  - Si $\delta \to +\infty$, la pénalisation domine et la courbe tend vers une droite, risque de sous-ajustement.
- le terme $\int (f''(t))^2 dt$ pénalise la rugosité de la fonction.

Ainsi, la solution est donnée par :

$$\hat{\beta} = (B^T B + \delta P)^{-1} B^T Y_i$$

où B est la matrice D × q dont la d-ième ligne est $(B_1(t_d), ..., B_q(t_d))$, $Y_i = (Y_{i1}, ..., Y_{iD})^T$ le vecteur des observations de l'entreprise i , et P est la matrice de pénalisation telle que $\beta^T P \beta = \int (f_i''(t))^2 dt$. La matrice P se calcule facilement à partir des dérivées secondes des fonctions de base B-splines.

### Choix du nombre de noeuds K

La règle de Ruppert et al. (2002) préconise $K = min(0.25 \times D, 35) = min(0.25 \times 672, 35) = min(168.75, 35) = 35$ noeuds, soit q = K + m = 39 fonctions de base. Dans gam(), nous arrondissons et utilisons le paramètre k=40, ce qui correspond à q=40, ce qui est cohérent avec la règle. De plus, le recours à la pénalisation permet d'utiliser un nombre de noeuds généreux sans risque de sur-ajustement, c'est le rôle de $\delta$.

Pour construire notre base B-splines, nous utilisons la fonction **create.bspline.basis()**, du package ***fda***. On lui spécifie :

- rangeval = c(1,p) : l'intervalle de définiton de la base, ici [1,672]
- nbasis = q : le nombre total de fonction de base, q = K+m = 40.
- norder = m : l'ordre des polynômes m=4, correspondant à des splines cubiques (m-1=3).

```r
K <- 35 # Nombre de noeuds
degree <- 3 # Degré des polynômes, m-1
m <- 4 # Ordre (degré+1)
q <- K + degree + 1 # nbasis = q = K+m

# Objet basisfd : notre base
base_bspline <- create.bspline.basis(
  rangeval = c(1, p),
  nbasis = q,
  norder = m
)
```

Soit $\delta$ le paramètre de lissage utilisé dans la reconstruction d'une courbe $Y_i$. Il peut être sélectionné en minimisant le critère de validation croisée généralisée (GCV).

Nous calculons donc le $\delta^*$ optimal pour chaque individu séparément en balayant une grille de valeurs $[10{-}5, 10^5]$. Une approche individuelle est plus rigoureuse qu'un $\delta$ commun car les entreprises peuvent avoir des profils de consommation très différents.

Pour chaque valeur de $\delta$, la fonction **fdPar()** du package ***fda*** crée un objet de paramètres fonctionnels encodant la base B-splines (base_bspline), l'ordre de dérivation utilisé pour la pénalisation (Lfdobj=2, correspondant à la dérivée seconde $f_i''$), et la valeur du paramètre de lissage $\delta$.

La fonction **smooth.basis()** va prendre en entrée les instants (times = [1:672]), les observations brutes $y_i$ et l'objet fdpPar contenant la base et le paramètre de pénalisation. Elle résout le critère pénalisé et retourne un objet contenant la courbe lisée $\hat{f}_i$ sous forme de coefficients B-splines, ainsi que la valeur du critère GCV. Le $\delta^*$ optimal est celui qui minise ce critère.

Deux fonctions sont définies :

- **calcul_gcv()** : calcule le critère GCV pour un individu i et une valeur $\delta$ donnée.
- **delta_opt_i()** : retourne le $\delta^*$ optimal pour l'individu i en balayant toute la grille.

```
#Grille des paramètre de lissage à tester
delta_grid <- 10^seq(-5, 5, by=0.5)

#Calcul GCV
calcul_gcv <- function(y_i, delta){
  res <- fdPar(base_bspline, Lfdobj = 2, lambda = delta)
  mean(smooth.basis(time, y_i, res)$gcv)
}

#Choisi le delta optimal qui minimise GCV, en balayant la grille
delta_opt_i <- function(i){
  y_i <- as.numeric(smart.278co[i, ])
  gcv_val <- sapply(delta_grid, calcul_gcv, y_i = y_i)
  delta_grid[which.min(gcv_val)]
}
```

Vérification de l'optimisation sur un individu de test :

```
set.seed(368)
#Sélection aléatoire d'un individu test
index_sample <- sample(1:n, 3)
i <- index_sample[2]

#Extraction des observation de l'individu i
y_i <- as.numeric(smart.278co[i, ])

#Calcul du delta optimal par GCV pour cet individu
delta_opt_i_test <- delta_opt_i(i)
cat("Le delta optimal pour l'individu : ",i," est ", delta_opt_i_test)
```

```
## Le delta optimal pour l'individu :  1715  est  31.62278
```

```
#Calcul du gcv pour chaque valeur de la grille (pour le plot)
gcv_val <- sapply(delta_grid, calcul_gcv, y_i = y_i)

#Dataframe pour Visualisation
df_plot_test1 <- data.frame( delta=delta_grid, gcv = gcv_val)

ggplot( df_plot_test1, aes(x=log10(delta), y=gcv)) +
  geom_line(color="darkblue") +
  geom_point(color="black")+
  #Delta optimal
```

```
  geom_vline(xintercept = log10(delta_opt_i_test), color="red")+
  theme_minimal()+
  labs( title = paste("Selection de delta par GCV pour l'individu", i),
        x="Paramètre de lissage en log",
        y="GCV(delta)")
```

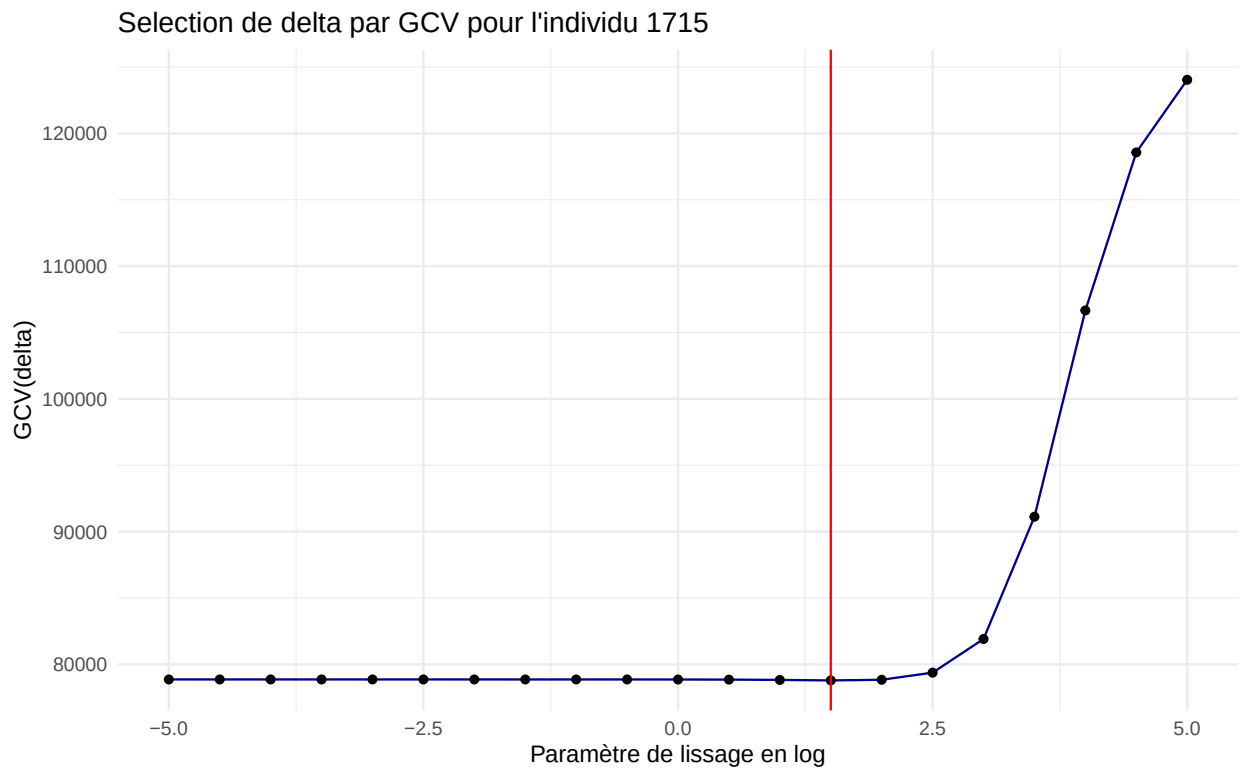


Visualisation de la courbe lissée :

```
#Création de l'objet fdPar avec le delta optimal trouvé
#Lfdobj = 2 : pénalisation dérivée seconde
res_i <- fdPar(base_bspline, Lfdobj = 2, lambda = delta_opt_i_test)

#Lissage de la courbe de l'individu i avec delta_opt
smooth_i <- smooth.basis(time, y_i, res_i)

#Evalusation de la courbe lissée aux instants time
y_lisse <- as.numeric(eval.fd(time, smooth_i$fd))

#Données brutes et courbe lissée dans un dataframe
df_i_fda <- data.frame(temps = time, y = y_i, lisse = y_lisse)

# Plot global sur 2 semaines
#données brutes : gris
#courbe lissée : violet
ggplot(df_i_fda, aes(x = temps)) +
  geom_line(aes(y = y), linewidth = 0.7, alpha = 0.5) +
  geom_line(aes(y = lisse), color = "purple", linewidth = 0.8) +
```

```
  geom_vline(xintercept = seq(48, 672, by = 48), linewidth = 0.5, linetype = "dashed") +
  theme_minimal() +
  labs(title = "Approximation B-spline sur 2 semaines", x = "Temps", y = "Consommation")
```

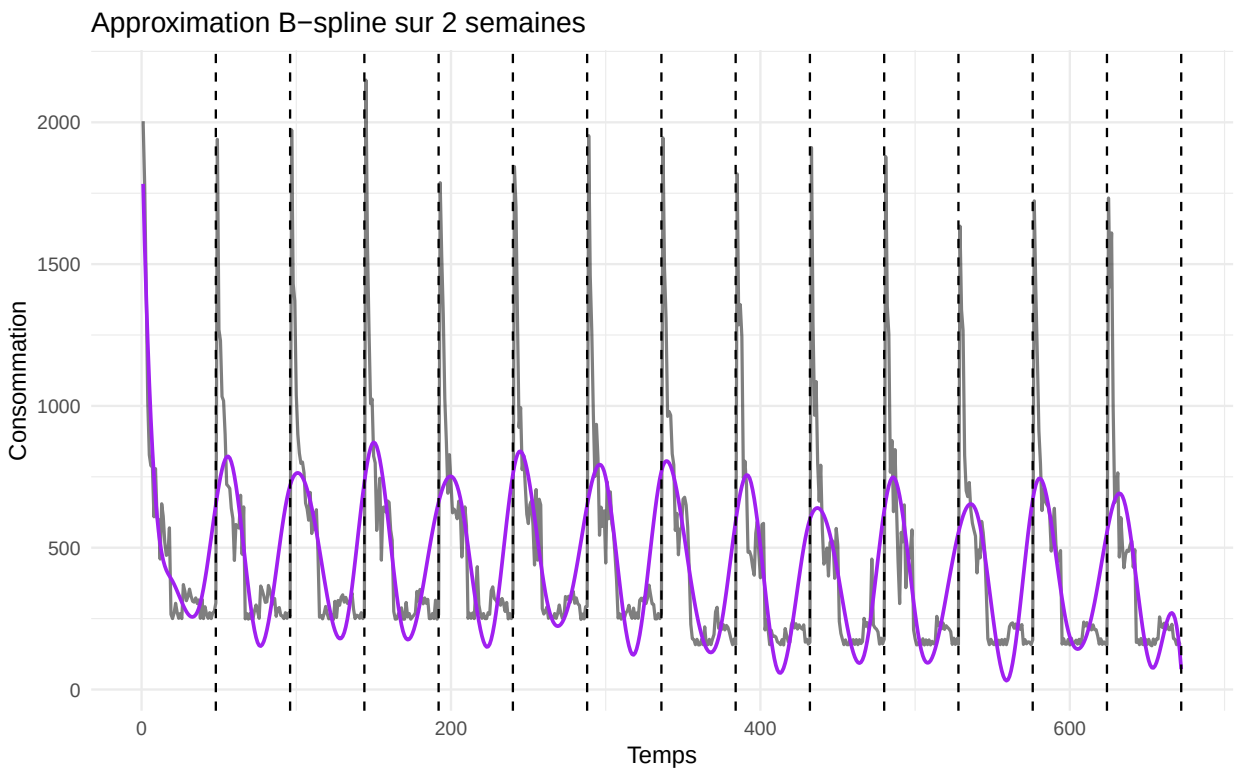


Nous pouvons maintenant, de la même façon, l'appliquer à l'ensemble des individu (utilisé pour l'approche 2 PCA).

Cependant, le calcul du $\delta^*$ pour chaque individu étant couteux en temps de calcul (environ 10-15 min pour les n=6 291 entreprises), les résultats sont calculés une seule fois et sauvegardés dans un fichier .rds. Ils sont ensuite rechargés directement à chaque compilation du rapport.

```
deltas_res <- sapply(1:n, delta_opt_i)
```

Une fois les $\delta_i^*$ chargés, la fonction lisser_i() applique le lissage B-splines à chaque individu avec son paramètre optimal. Smooth.basis() retourne un objet fd par individu, c'est à dire n objets séparés. Or pca.fd() nécessite un seul objet fd contenant toutes les courbes.

Nous allons donc extraire les matrices de coefficients B-splines de chaque courbe lissée et les rassembler dans un unique objet fd via la fonction **fd(),** qui encode à la fois les coefficients$\beta_i$ de chaque individu et la base commune. C'est l'objet fd_final qui sera utilisé dans toute la suite de l'analyse.

```
#Lecture des deltas optimaux
deltas_res <- readRDS("donnees/deltas_res.rds")

#Fonction qui va permettre de lisser la courbe associée à l'individu i
lisser_i <- function(i){
  y_i <- as.numeric(smart.278co[i, ])
  res <- fdPar(base_bspline, Lfdobj = 2, lambda = deltas_res[i])
```

```r
  smooth.basis(time, y_i, res)$fd
}

#retourne list de 6291objets fd séparés -> pca.fd a besoin d'un seul objet
fd_list <- lapply(1:n, lisser_i)

#Extraire les coefs
extraire_coefs <- function(fd_i){
  as.numeric(fd_i$coefs)
}

coefs_mat <- sapply(fd_list, extraire_coefs)

#Reconstruire en un seul objet fd
fd_final <- fd(coefs_mat, base_bspline)
```

### Alternative 2 : Splines Pénalisées et modèle GAM

La méthode décrite ici provient du livre *Functional Data Analysis with R*. Le modèle est identique à l'Alternative 1. La seule différence réside dans la sélection du paramètre de lissage $\delta$ : au lieu d'une recherche manuelle par GCV sur une grille de valeur, celui-ci est estimé automatiquement par la méthode REML (Restricted Maximum Likelihood) intégrée à gam().

(petit passage sur méthode REML ?)

On utilise la fonction *gam*() du package **mgcv,** qui ajuste des modèles additifs. Elle prend en entrée un dataframe contenant les observation et une formule spécifiant les termes de lissage. Ici "s(Temps, bs="cr", k=40)", définit un terme de lissage non paramétrique sur la variable 'Temps'."cr", indique que l'on utilise des splines subiques de regréssion, et k=40 fixe la dimension de la base.

La fonction estime simultanément les coefficients $\hat{\beta}$ et le paramètre de lissage $\delta$ optimal par REML, et retourne un objet contenant la courbe lissée ainsi que tous les critères d'ajustements.

### Exemple sur un individu

```r
# on extrait le premier individu pour la démo
ind_1 <- as.numeric(table[1,])
df_1 <- data.frame(Temps=time, Var=ind_1)

# modèle de lissage
modele_gam <- gam(Var ~ s(Temps, bs = "cr", k = 40),
                  data = df_1,
                  method = "REML")

summary(modele_gam)
```

```
##
## Family: gaussian
## Link function: identity
##
## Formula:
## Var ~ s(Temps, bs = "cr", k = 40)
```

```
##
## Parametric coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   228.31      11.01   20.73   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Approximate significance of smooth terms:
##            edf Ref.df     F p-value
## s(Temps) 34.32  37.64 6.624  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## R-sq.(adj) =  0.271   Deviance explained = 30.8%
## -REML = 4818.9  Scale est. = 81510     n = 672
```

Contrairement à la première alternative où le paramètre de lissage optimal devait être recherché manuellement via une grille de valeurs et la validation croisée généralisée (GCV), la fonction $gam()$ automatise ce processus.

En spécifiant $method =$ "REML", l'algorithme reformule le problème de lissage sous la forme d'un modèle mixte. Le paramètre de pénalité $\delta$ est alors estimé directement, comme un ratio entre la variance du signal et la variance du bruit.

Le degré de lissage optimal est ainsi obtenu en une seule étape, sans risque de sous-lissage.

```r
# prédiction de la courbe lisse
df_1$Courbe_Lisse <- predict(modele_gam, newdata = df_1)

# données brutes VS signal estimé
ggplot(df_1, aes(x = Temps)) +
  geom_line(aes(y = Var), alpha = 0.3, color = "black", size = 1) +
  geom_line(aes(y = Courbe_Lisse), color = "red", linewidth = 1.2) +
  theme_minimal() +
  labs(title = "Lissage semi-paramétrique d'un individu",
       x = "Temps (Intervalles de 30 min sur 2 semaine)",
       y = "Variable")
```

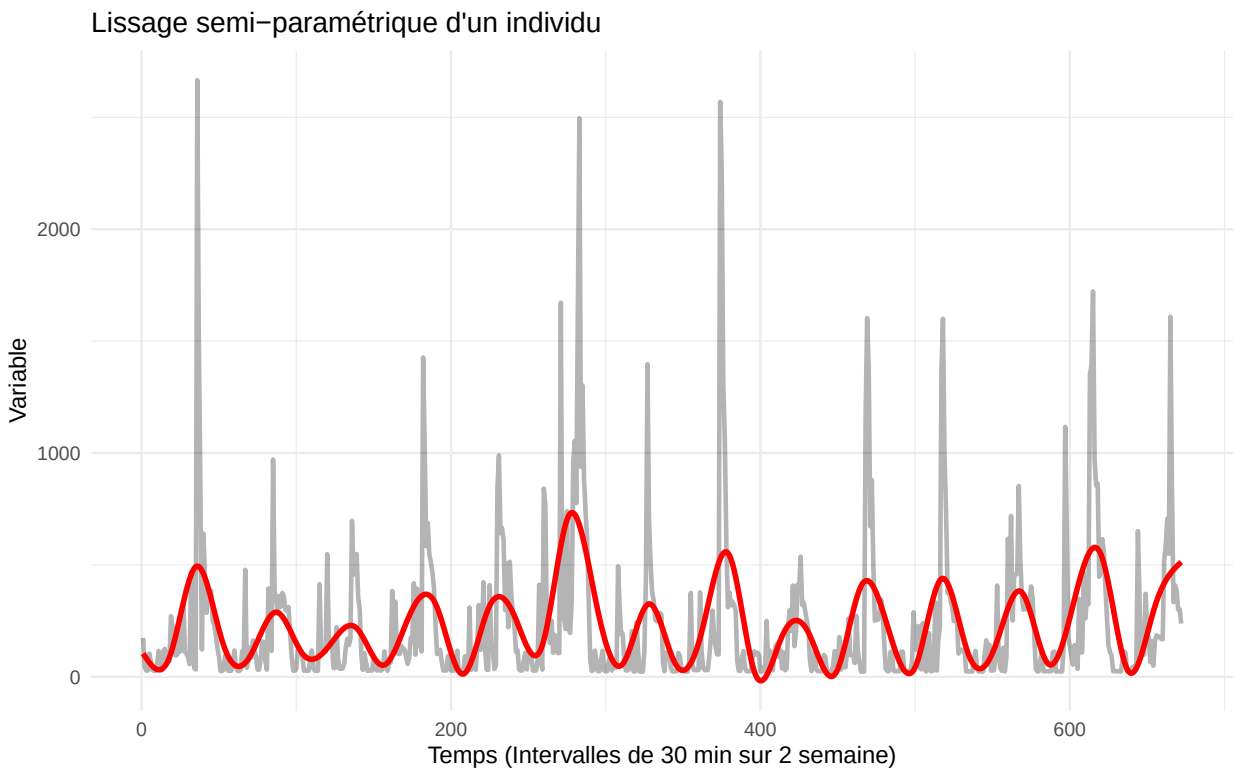


```
# summary(modele_gam)
```

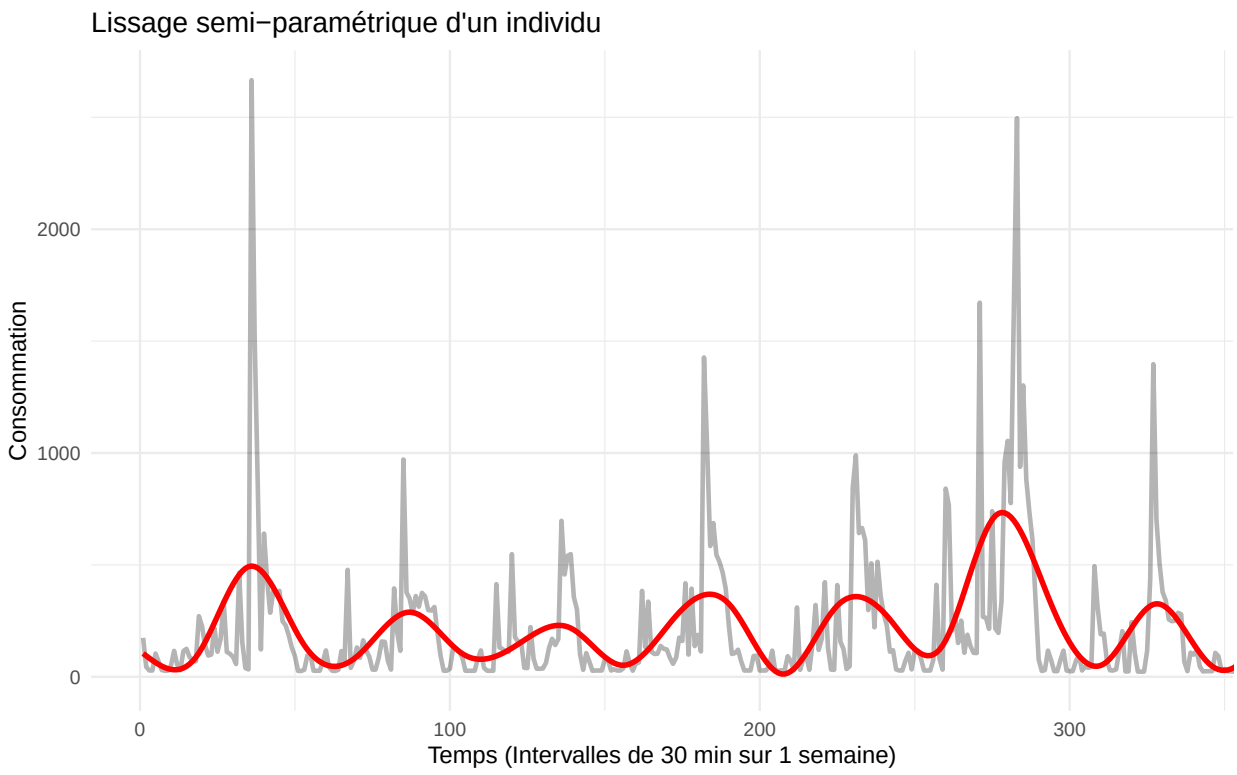

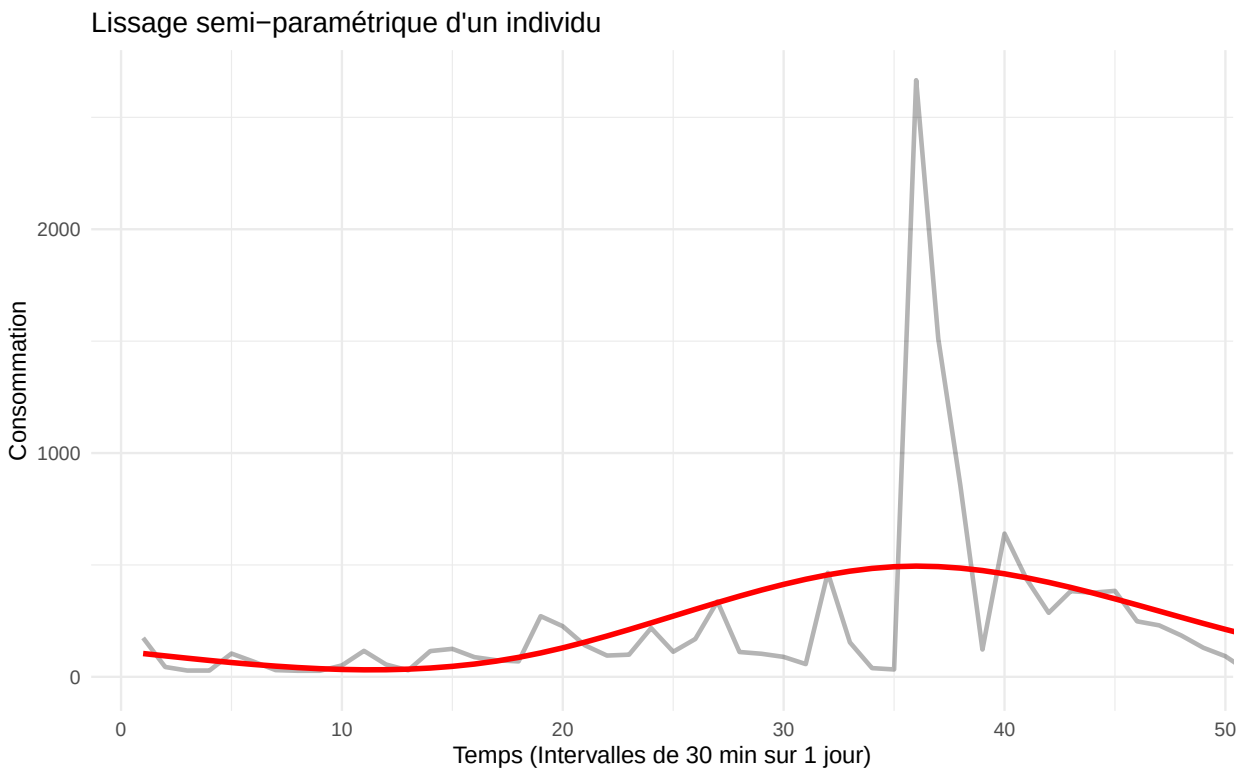


Les grandes vagues dessinées par la courbe rouge représentent le rythme quotidien de consommation du premier individu. On remarque 14 pics et 14 creux. on en déduit que les creux correspondent aux périodes de faible consommation (la nuit) et les pics les périodes de haute consommation (milieu de journée).

Après avoir testé sur un individu et visualiser la qualité du lissage, on applique à l'ensemble des n = 6291 individu.

### Application à tous les individus (pour approche 2 PCA)

Lors de l'exploration des données, 16 entreprises ont une consommation constante sur l'ensemble des deux semaines. Parmi elles, 15 affichent une consommation nulle sur les 672 instants, et une seule présente une valeur constante non nulle égale à 9. Ces profils ont donc une variance strictement nulle, ce qui pose problème lors l'estimation du paramètre de lissage $\delta$. En effet, $gam()$ ne peut pas ajuster un modèle sans variabilité.

Nous avons donc décidé d'exclure ces 16 individus de l'analyse, l'effectif final est donc n = 6275.

```
#Individu ayant un consommation nulle
#Renvoie True si la variance de l'individu i = 0 / conso constante
verif_conso <- function (i){
  y_i <- as.numeric(smart.278co[i, ])

  var(y_i)==0 || any(!is.finite(y_i))
}

probleme_conso <- sapply(1:n, verif_conso)
idx_pb <- which(probleme_conso)
idx_ok <- which(!probleme_conso)
cat("Nombre d'ind avec conso constantes :", length(idx_pb),"\n")
```

```
## Nombre d'ind avec conso constantes : 16
```

```r
cat("Nombre d'ind ok :", length(idx_ok))
```

```
## Nombre d'ind ok : 6275
```

```r
#Fonction pour lisser chaque courbe de chaque individu
lisser_gam_i <- function(i){

  y_i <- as.numeric(smart.278co[i, ])

  df_i <- data.frame(Temps = time, Y=y_i)

  mod <- gam(Y~ s(Temps, bs = "cr", k = 40),
                 data = df_i,
                 method = "REML")

  #Recuperer le delta optimal trouvé par REML
  delta_opt <- mod$sp
  res <- fdPar(base_bspline, Lfdobj = 2, lambda = delta_opt)
  smooth.basis(time, y_i, res)$fd
}

#Matrice pxn des courbes lissées
fd_list <- lapply(idx_ok, lisser_gam_i)
coefs   <- sapply(fd_list, function(fd_i) as.numeric(fd_i$coefs))
fd_final <- fd(coefs, base_bspline)
#Ligne executée qu'une fois
saveRDS(fd_final, file = "donnees/fd_final.rds") #15-20 min
```

```r
#chargement du lissage
fd_final <- readRDS("donnees/fd_final.rds")
```

# Analyse en Composantes Principales Fonctionnelle (ACPF)

L'Analyse en Composantes Principales Fonctionnelle (FPCA) permet de résumer la variabilité des courbes $Y_i(t)$ autour de leur moyenne fonctionnelle $\mu(t)$.

Le principe consiste à rechercher des fonctions propres $\phi_k(t)$ maximisant la variance projetée :

$$Y_i(t) = \mu(t) + \sum_{k=1}^{\infty} \xi_{ik}\phi_k(t)$$

où :

- $\mu(t)$ est la courbe moyenne de la population,
- $\phi_k(t)$ sont les fonctions propres,
- $\xi_{ik} = \int (Y_i(t) - \mu(t))\phi_k(t)dt$ sont les scores principaux de l'individu i, obtenu en projetant sa courbe centrée sur la fonction propre $\phi_k$. Ils mesurent à quel point la courbe de l'individu i s'écarte de la moyenne dans la direction $\phi_k$.

Les fonctions propres $\phi_k(t)$ sont obtenues en digonalisant l'opérateur de covariance : $C(s,t) = \frac{1}{n}\sum_{i=1}^{n}(Y_i(s) - \mu(s))(Y_i(t) - \mu(t)$. Contrairement àl'ACP traditionnelle où c'est une matrice de covariance qui est diagonalisée, ici c'est un opérateur de covariance.

**Remarque :** Les courbes sont centrées par rapport à la moyenne $\mu(t)$ mais pas réduites. Contrairement à l'ACP traditionnelle sur données multivariées, on ne divise pas par l'ecart-type car toutes les mesures sont dans la même unité (la consommation électrique).

## Approche 1 : pca.fd() - package fda

Cette approche consiste à d'abord lisser individuellement les courbes (section précédente), puis à appliquer l'ACPF via la fonction **'pca.fd()' du package 'fda'**. L'objet **'fd' passé en entrée, contient les coefficients B-splines $\hat{\beta}_i$ de chaque courbe lissée $\hat{f}_i$, ainsi que la base de B-splines commune. A partir de ces coefficients, 'pca.fd()'** estime l'opérateur de covariance **C(s,t),** défini récédemment, puis en extrait les fonctions propres $\phi_k$ et les scores $\xi_{ik}$ par diagonalisation.

```r
# PCA fonctionnelle
pca_res <- pca.fd(fd_final, nharm = 10)

# Variance expliquée
var <- pca_res$varprop *100
var_cum <- cumsum(pca_res$varprop*100)

data.frame(FP  = 1:10,
           prop = round(var[1:10], 2),
           cum  = round(var_cum[1:10], 2))
```

```
##    FP  prop   cum
## 1   1 78.57 78.57
## 2   2  9.40 87.97
## 3   3  4.09 92.06
## 4   4  2.04 94.09
## 5   5  0.73 94.82
## 6   6  0.55 95.37
## 7   7  0.50 95.87
## 8   8  0.35 96.22
## 9   9  0.32 96.54
## 10 10  0.29 96.83
```

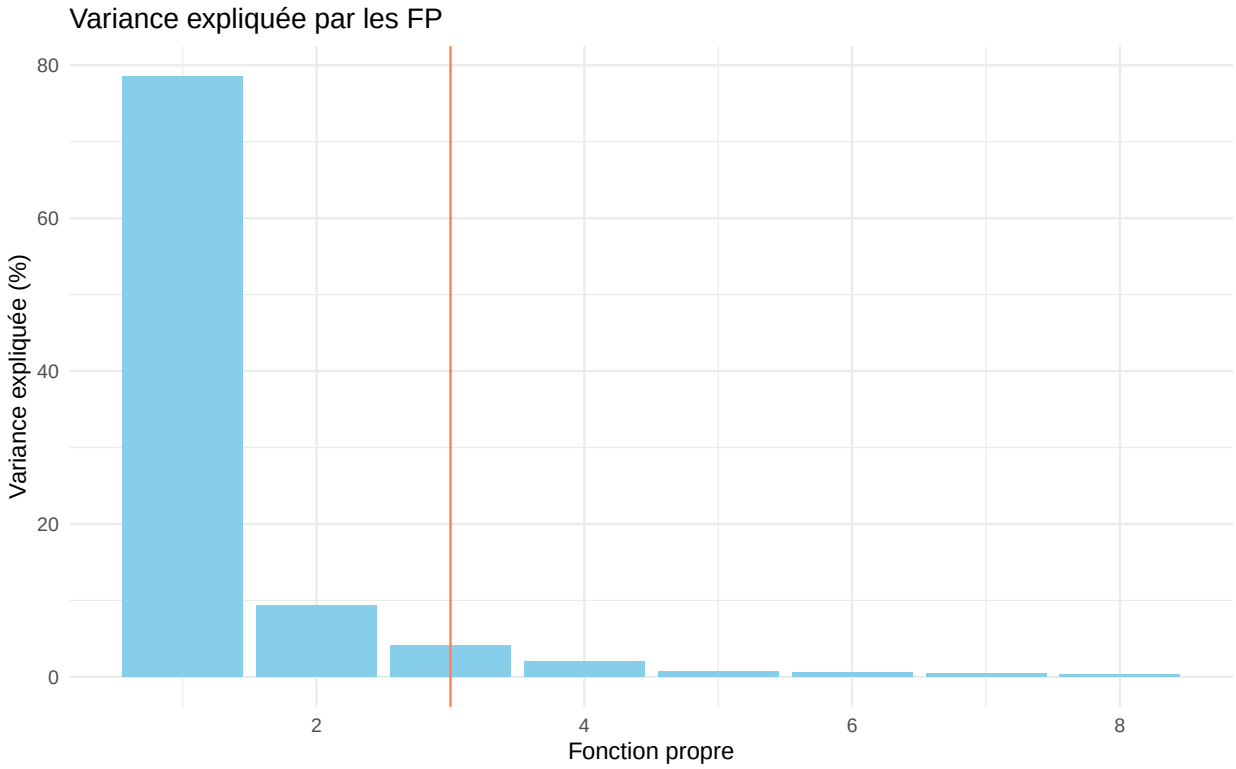
Variance expliquée par les FP
Variance expliquée (%)
80
60
40
20
0
2
4
6
8
Fonction propre

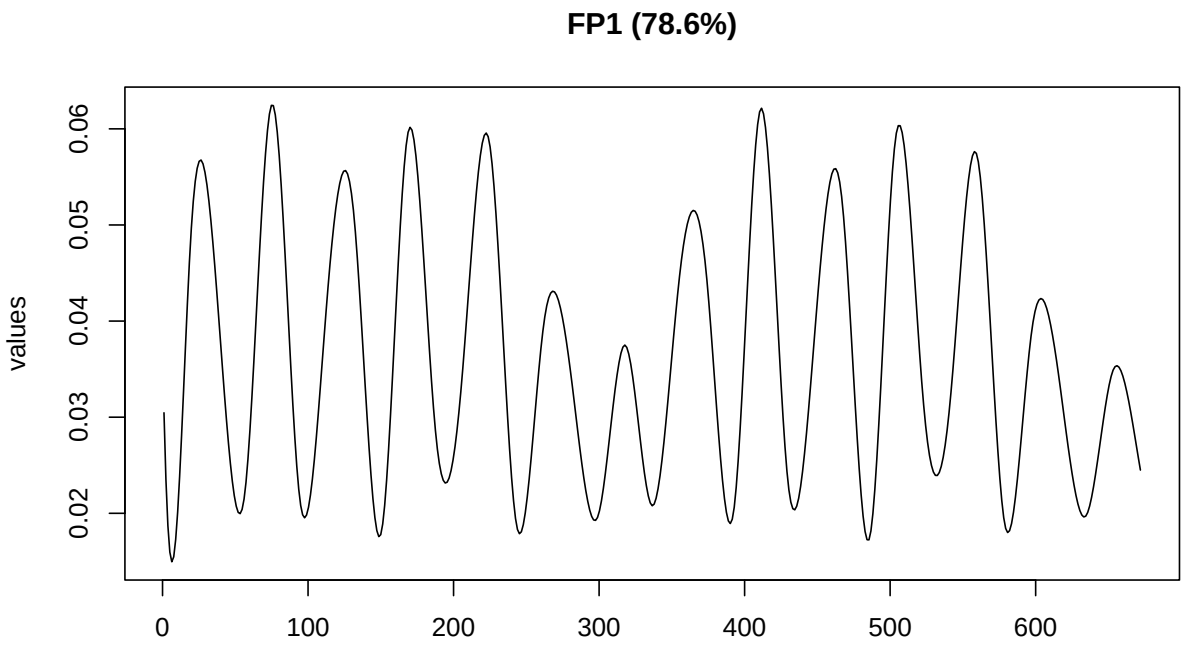
FP1 (78.6%)
values
0.02
0.03
0.04
0.05
0.06
0
100
200
300
400
500
600

```
## [1] "done"
```

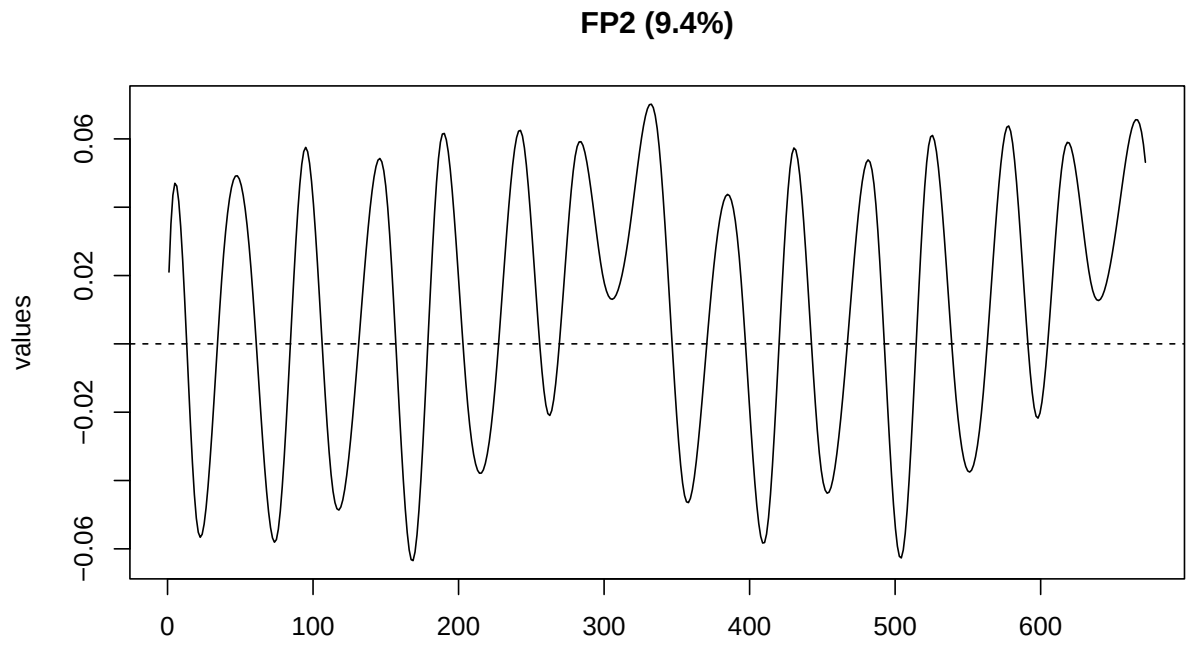
FP2 (9.4%)
values
0.06
0.02
−0.02
−0.06
0
100
200
300
400
500
600

```
## [1] "done"
```

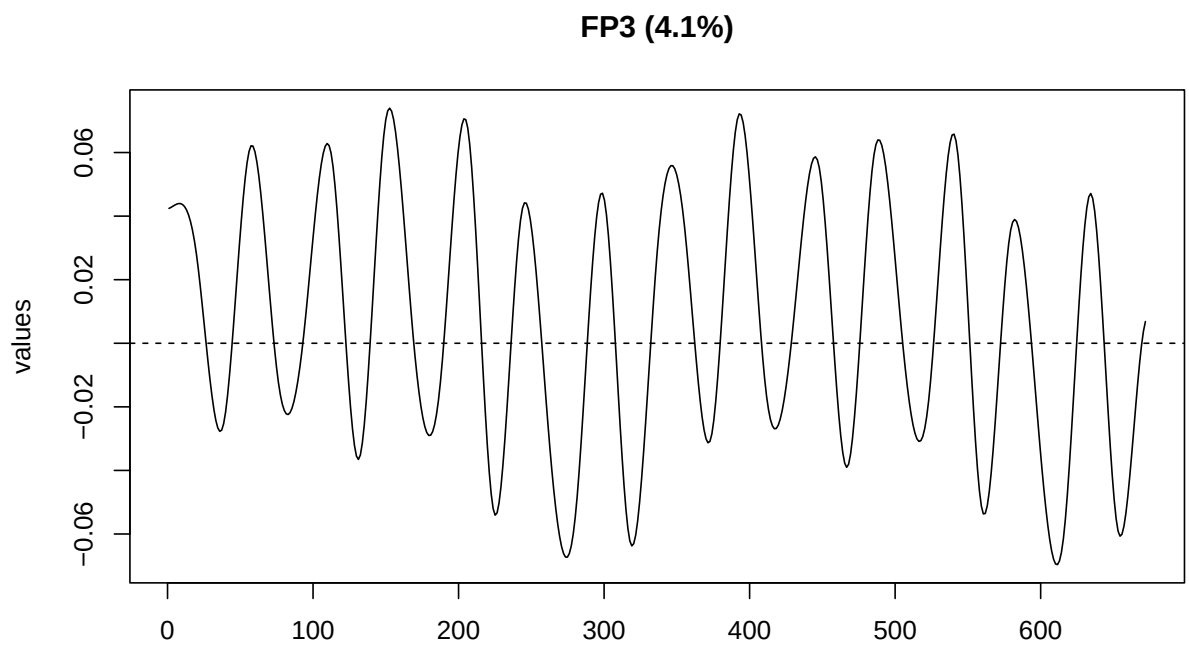
FP3 (4.1%)
values
0.06
0.02
−0.02
−0.06
0
100
200
300
400
500
600

```
## [1] "done"
```

Les deux premières fonctions propres :

CP1 - La première fonction propre présente une forme positive et régulière sur l'ensemble des deux semaines, avec une structure périodique journalière visible. Elle explique la majeure partie de la variance totale.

CP2 - La deuxième fonction propre oscille entre le positif et le négatif, traduisant un contraste temporel dans les profils de consommation.

Une interprétation physique détaillée de ces composantes est proposées dans l'Approche 2 (section suivante).

## Approche 2 : fpca.face() — package refund

Approche, proposée par Xiao et al. (2016) repose sur une idée différente de l'approche 1 : au lieu de lisser les individus un à un, puis d'estimer l'opérateur de covariance à partir de courbes lissées, on estime et lisse *directement* la matrice de covariance globale C(s,t) à partir des données brutes. Concrètement, la méthode FACE (Fast Covariance Estimation) procède en deux étapes :

- Elle estime d'abord la matrice de covariance brute à partir des n courbes observées.
- Elle lisse ensuite cette matrice de covariance par splines pénalisées, ce qui permet d'en extraire des fonctions propres $\phi_k$ et les scores de chaque individu, sans avoir à lisser les individus un à un.

Cette approche est particulièrement pratique pour des grands jeux de données car elle évite n opérations de lissage individuelles.

On utilise donc la fonction $fpca.face()$ du package $refund$ qui implémente cet algorithme .On extraie ici les deux premières composantes (PC1 et PC2), que l'on multiplie par la suite par $\sqrt{p}$ (c'est le bouquin qui dit qu'il faut le faire, jai pas trop compris pourquoi...) On lui demande 50 noeuds ($knots = 50$) et de retenir les composantes expliquant 95% de la variance ($pve = 0.95$).

```
W <- as.matrix(table)

modele_fpca <- fpca.face(Y = W, argvals = time, knots = 50, pve = 0.95)
# summary(modele_fpca)

#on extraie les éléments de la FCPA
courbe_moyenne <- modele_fpca$mu
fonctions_propres <- modele_fpca$efunctions
scores_individuels <- modele_fpca$scores
valeurs_propres <- modele_fpca$evalues

variance_expliquee <- valeurs_propres / sum(valeurs_propres)

# on extrait les fonctions propres
pc1 <- fonctions_propres[, 1] * sqrt(p)
pc2 <- fonctions_propres[, 2] * sqrt(p)

data_plot <- data.frame(Temps = time, FP1 = pc1)
data_plot2 <- data.frame(Temps = time, FP2 = pc2)


# Variance expliquée
var2     <- modele_fpca$evalues / sum(modele_fpca$evalues) * 100
var_cum2 <- cumsum(var2)
nb_cp2 <- min(which(var_cum2 >= 90))
```

```r
df_var2 <- data.frame(
  FP   = 1:length(var2),
  prop = var2
)

ggplot(df_var2, aes(x = FP, y = prop)) +
  geom_col(fill = "skyblue", alpha = 0.8) +
  geom_vline(xintercept = nb_cp2, color = "coral", linetype = "dashed", linewidth = 1) +
  theme_minimal() +
  labs(title = "Approche 2 - Variance expliquée (fpca.face)",
       x = "Fonction propre", y = "Variance expliquée (%)")
```

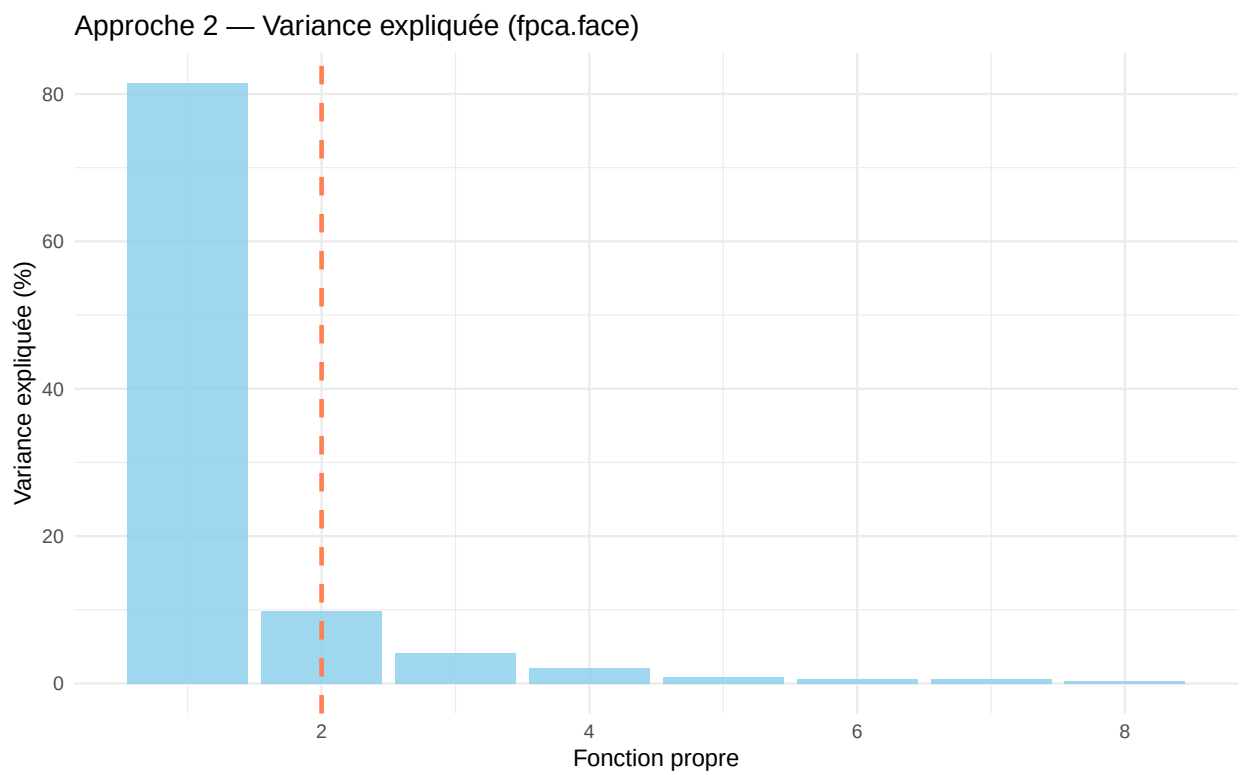


```r
df_var2
```

```
##   FP       prop
## 1  1 81.5122791
## 2  2  9.9030870
## 3  3  4.0723509
## 4  4  2.1297840
## 5  5  0.8201363
## 6  6  0.6269994
## 7  7  0.5553995
## 8  8  0.3799638
```

```r
# visualisation de la PC1
ggplot(data_plot, aes(x = Temps)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray") +
```

```r
  geom_line(aes(y = FP1), color = "blue", linewidth = 1.2) +
  theme_minimal() +
  labs(title = "FP1",
       x = "Temps (Intervalles de 30 min sur 2 semaines)",
       y = "Variation (FP1)")
```

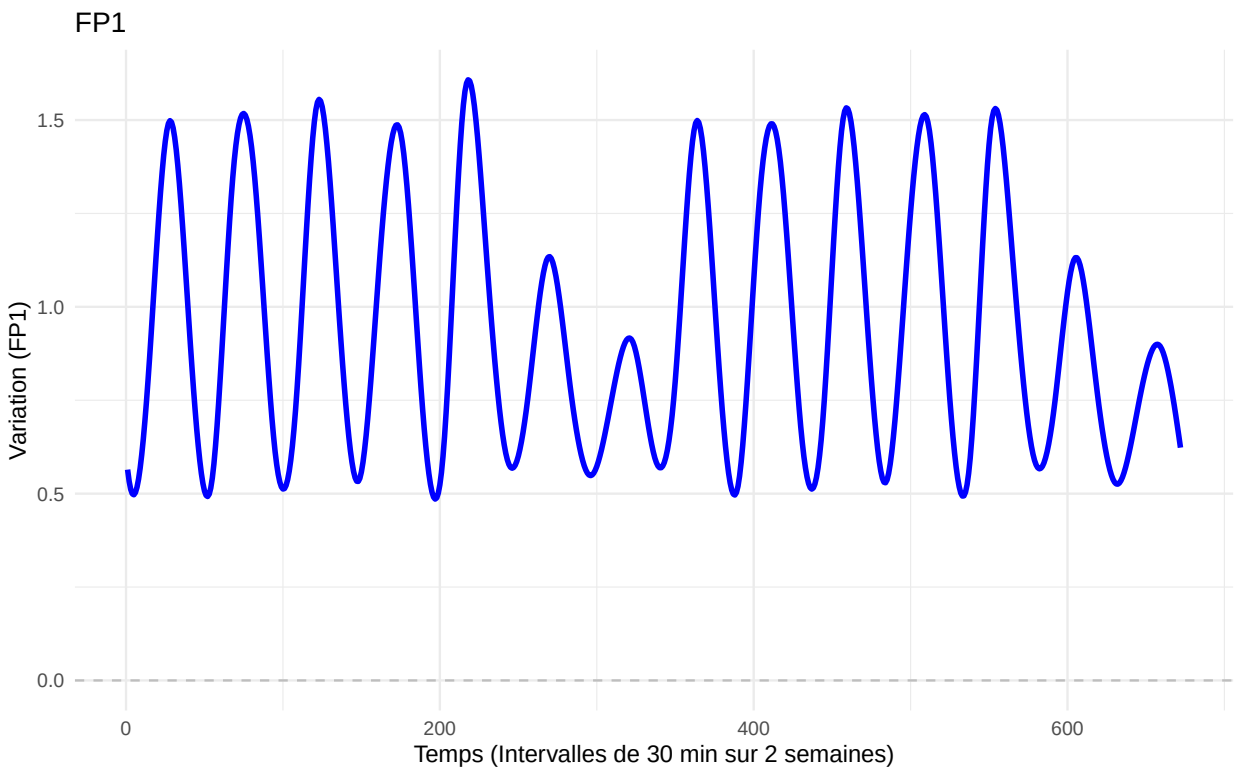


On observe une courbe strictement positive qui présente une strucutre périodique régulière sur les deux semaines. On remarque que le même schéma se répète chaque jours : des pics en journée et des creux pendant la nuit. On distingue également une différence entre les jours de semaine et le week-end. En effet les pics du week-end sont différents en amplitude, montrant un comportement de consommation distincts les jours non travaillés.

```r
# visualisation de la PC2
ggplot(data_plot2, aes(x = Temps)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray") +
  geom_line(aes(y = FP2), color = "blue", linewidth = 1.2) +
  theme_minimal() +
  labs(title = "2ème Composante Principale Fonctionnelle (FP2)",
       x = "Temps (Intervalles de 30 min sur 2 semaine)",
       y = "Variation (FP2)")
```

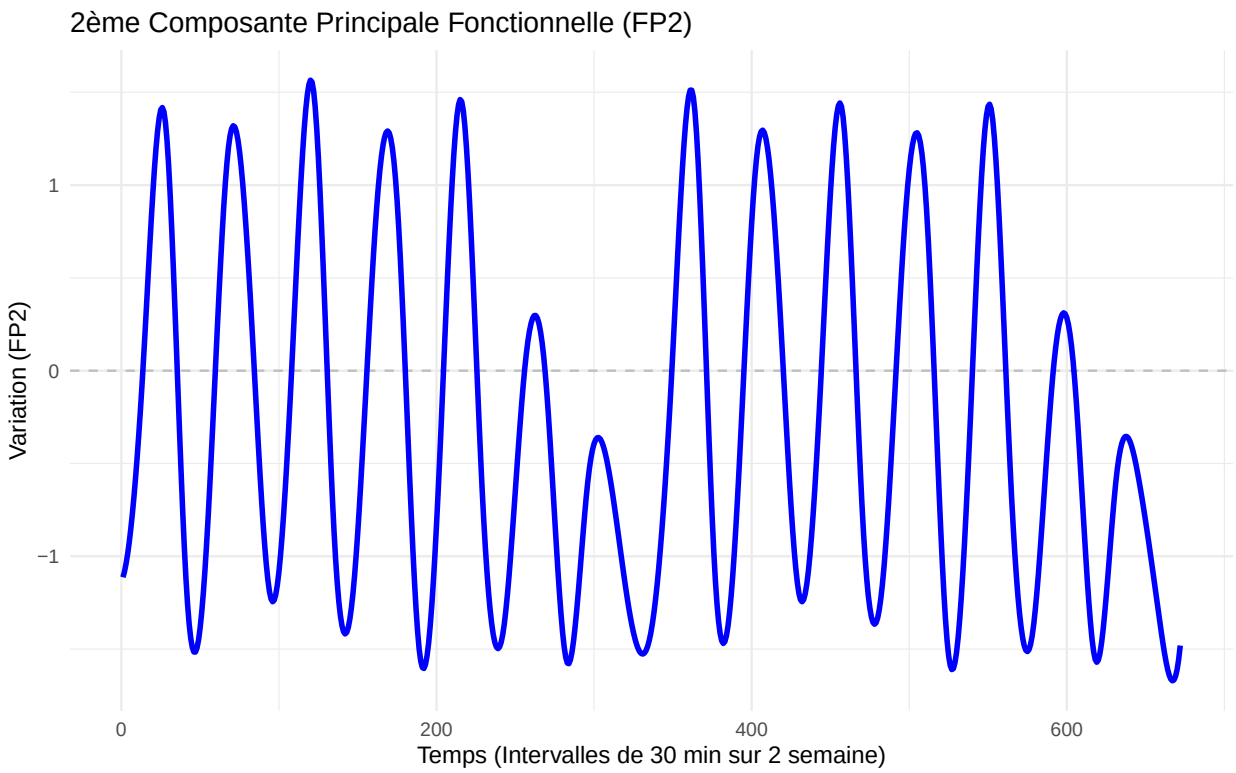


On observe là aussi une courbe qui ondule mais cette fois qui prend des valeurs négatives ou nulles.

### Interpréation de la FP1

La courbe de la première composante est assez abstraite. On cherche à comprendre ce que la PC1 mesure physiquement sur notre jeu. Pour essayer de traduire, on isole les comportements extrêmes de la population : les individus dans le top 10% des scores de la PC1 et ceux dans le bottom 10% de la PC1. On calcule ensuite la vraie courbe moyenne de ces deux groupes pour observer comment la PC1 affecte la forme globale de la productio sur une semaine.

```
#score de la composante 1
scores_pc1 <- modele_fpca$scores[, 1]

seuil_haut <- quantile(scores_pc1, 0.90)
seuil_bas <- quantile(scores_pc1, 0.10)

#individus extrêmes
index_haut <- which(scores_pc1 >= seuil_haut)
index_bas <- which(scores_pc1 <= seuil_bas)

#vraies moyennes pour groupes extrêmes
courbe_moyenne_top10 <- colMeans(W[index_haut, ])
courbe_moyenne_bot10 <- colMeans(W[index_bas, ])

#dataframe pour graphique
df_interpretation <- data.frame(
  Temps = rep(time, 3),
```

```r
  Activite = c(courbe_moyenne_top10, courbe_moyenne_bot10, courbe_moyenne),
  Groupe = rep(c("Top 10% (Scores PC1 forts)",
                 "Bottom 10% (Scores PC1 faibles)",
                 "Moyenne Globale"), each = 672)
)

ggplot(df_interpretation, aes(x = Temps, y = Activite, color = Groupe)) +
  geom_line(linewidth = 1) +
  scale_color_manual(values = c("Top 10% (Scores PC1 forts)" = "red",
                                "Bottom 10% (Scores PC1 faibles)" = "blue",
                                "Moyenne Globale" = "black")) +
  geom_vline(xintercept = seq(96, 672, by = 96), color = "gray", linetype = "dotted") +
  theme_minimal() +
  labs(title = "Interprétation Physique de la Composante 1",
       x = "Temps (Intervalles de 15 min sur 1 semaine)",
       y = "Volume de la variable",
       subtitle = "Comment se comportent dans la vraie vie les extrêmes de la FP1 ?")
```

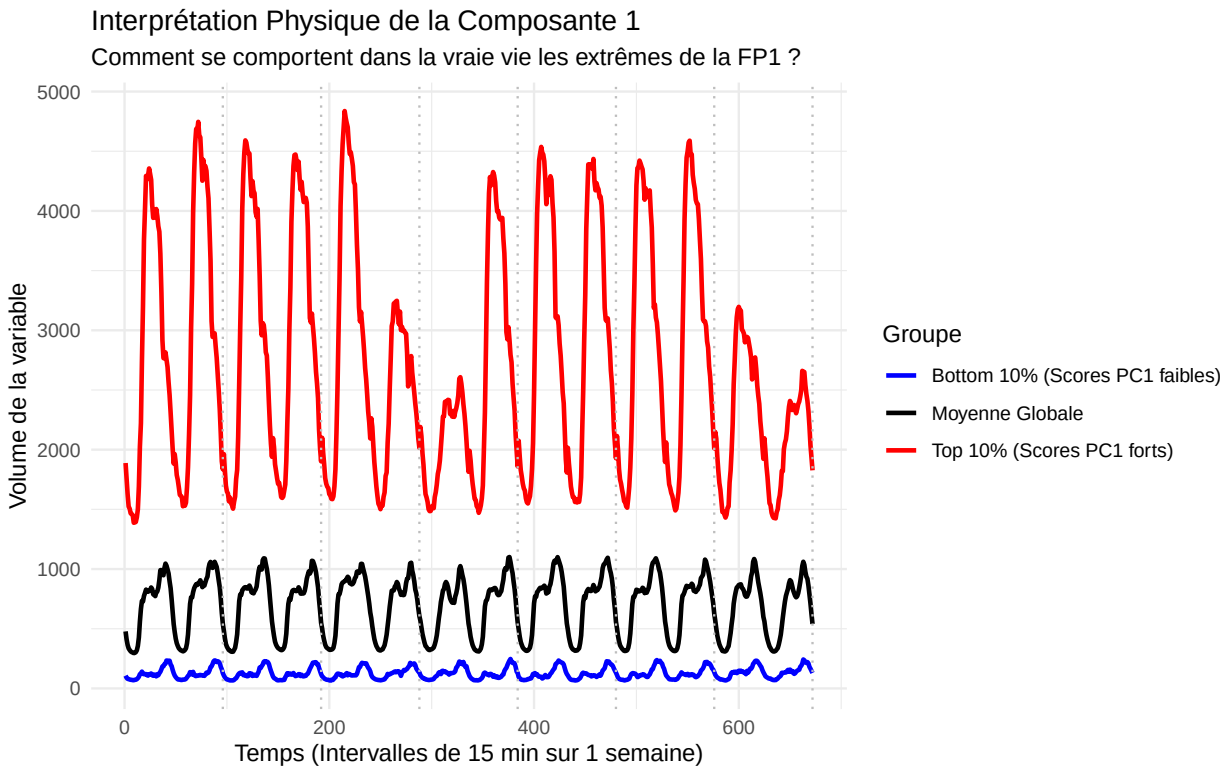


On déduit que la première composante agit comme un multiplicateur global sur les deux semaines. On constate que les individus du top 10% consomment massivement plus d'énergie que la moyenne. Leurs pics journaliers sont également bien plus importants. A l'inverse, la consommation du Bottom 10% semble presque plate sur l'échelle du réseau.

### Interpréation de la FP2???

## GFCPA

### Normalité

La FCPA décrite dans le premier point suppose que les données suivent une loi normale (d'après le chapite 3.2). Nous allons vérifier cette hypothèse sur le premier instant temporel :

```
qqnorm(df[,1])
```

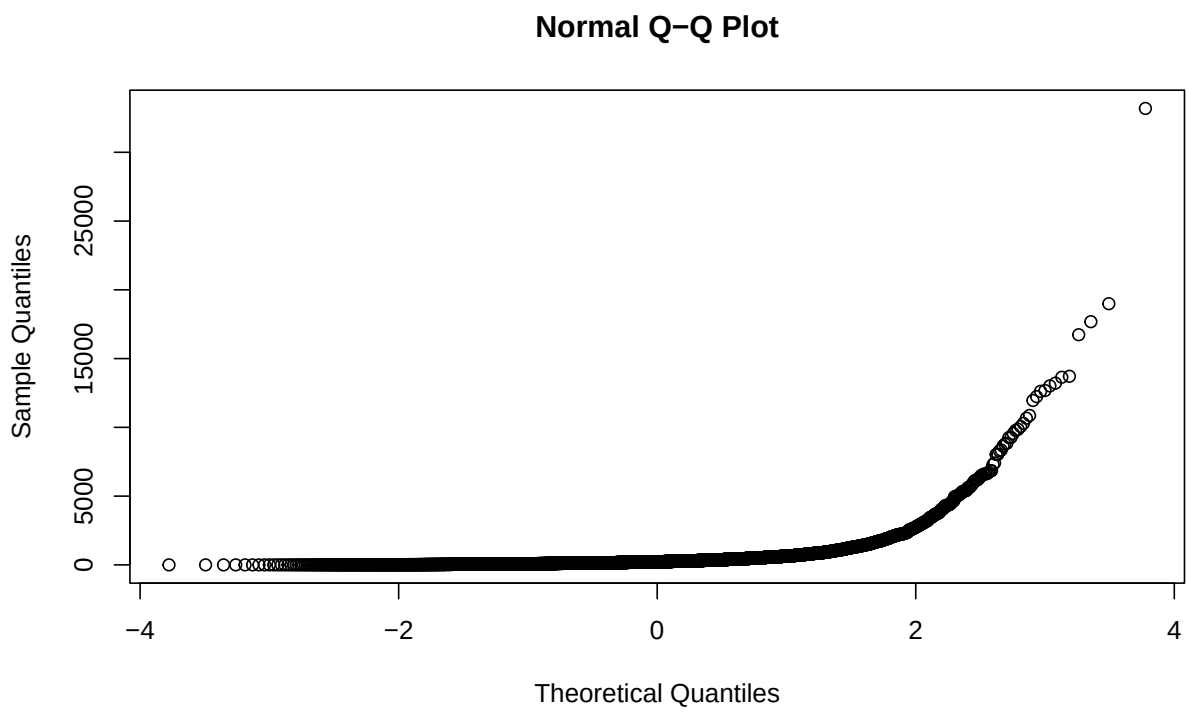


On voit que les points ne s'alignent pas sur une droite. Ainsi, nos données de consommation ne sont pas gaussiennes sur le premier instant d'où l'utilité de la méthod

### Préparation et méthode de binning (fenêtrage)

Lobjectif est ici de préparer les données pour les algorithmes de modèles mixtes. En premier lieu nous convertissons notre data frame en format long i.e une ligne par observation temporelle par individu. Ensuite, nous appliquons la méthode du Binning : au lieu de calculer un modèle mixte pour chacun des 672 points sur 6291 individus (ce quiserait trop complexe), on regroupe les intervalles de 30mn en blocs de 4 heures (8 intervalles).

```
p <- 672
n <- nrow(W)

df_long <- data.frame(
```

```r
  ID = as.factor(rep(1:n, times = p)),
  Temps = rep(1:p, each = n),
  Production = as.vector(W)
)

# binning
taille_fenetre <- 8

df_long <- df_long %>%
  mutate(Fenetre = floor((Temps - 1) / taille_fenetre) * taille_fenetre + (taille_fenetre / 2))

centres_fenetres <- unique(df_long$Fenetre)
```

### Modèles mixtes locaux

Pour chaque bloc de 4 heures on isole les données et on ajuste un modèle mixte grâce à la fonction $glmer()$. Puisque nous traitons des données semblables à des données de "comptage", nous utilisons la loi de Poisson avec un lien logarithmique ($family = poisson(link = "log")$). La valeur extraite pour chaque centrale est son effet aléatoire i.e son écart latent par rapport à la moyenne à la moyenne du réseau durant ces 4 heures.

Pour la fenêtre temporelle $j$, on modélise la production $Y_{ij}$ de la centrale $i$ par :

$Y_{ij} \sim \mathcal{P}(\mu_{ij})$

$\log(\mu_{ij}) = \beta_0 + b_{ij}$

Où $\mu_{ij}$ est la consommation moyenne théorique de la centrale $i$ durant la fenêtre temporelle $j$, $\beta_0$ est l'intercepte fixe (la moyenne globale) et $b_{ij}$ est l'effet aléatoire (la déviation latente propre à la centrale $i$).

Pour extraire les effets aléatoires de chaque modèle on utilise la fonction $ranef()$.

```r
# matrice qui stocke les effets aléatoires
matrice_effets_locaux <- matrix(NA, nrow = n, ncol = length(centres_fenetres))

for (j in 1:length(centres_fenetres)) {
  fenetre_actuelle <- centres_fenetres[j]
  data_locale <- subset(df_long, Fenetre == fenetre_actuelle)

  modele_local <- glmer(Production ~ 1 + (1 | ID),
                        family = poisson(link = "log"),
                        data = data_locale)

  matrice_effets_locaux[, j] <- ranef(modele_local)$ID[[1]]
}
```

Nous allons maintenant lisser les signaux latents obtenus par fenêtres pour retrouver des profils de consommation continus sur les deux semaines entières. Pour cela, nous appliquons la FCPA classique sur la matrice des effets aléatoires pour lisser les sauts entre les fenêtres de 4h. Une fois les fonctions propres $\phi_k$ extraites nous les interpolons pour repasser à 672 intervalles de 30mn.

La décomposition des signaux latents lissés s'écrit comme suit :

```r
# fcpa classique aux signaux latents
fpca_latente <- fpca.face(Y = matrice_effets_locaux, pve = 0.95)
```

```r
K <- ncol(fpca_latente$efunctions)

#interpolation des composantes piur repasser aux fenêtres de 30mn
fonctions_propres_interpolees <- matrix(NA, nrow = p, ncol = K)
for (k in 1:K) {
  fonctions_propres_interpolees[, k] <- approx(x = centres_fenetres,
                                               y = fpca_latente$efunctions[, k],
                                               xout = 1:p)$y
}

for(k in 1:K) {
  df_long[[paste0("phi_", k)]] <- fonctions_propres_interpolees[df_long$Temps, k]
}
```

D'après le chapitre 3.2, le binning a tendance à trop lisser les différences entre les individus. Pour corriger cela, nous lançons un grand modèle additif final (via la fonction $bam()$, une version de $gam()$ pour les grands jeux de données) défini par :

$$\log(\mu_i(t)) = f(t) + \xi_{i1}\phi_1(t) + \xi_{i2}\phi_2(t)$$

Où $f(t)$ est la fonction lisse moyenne globale, et $\xi_{i1}, \xi_{i2}$ sont les scores ré-estimés de manière optimale pour chaque centrale.

```r
#on echantillonne pour que ça prenne moins de temps à compiler
df_long_echantillon <- subset(df_long, as.numeric(ID) <= 500)

for (k in 1:2) { # On boucle sur les 2 composantes
  df_long_echantillon[[paste0("phi_", k)]] <- approx(x = centres_fenetres,
                                                     y = fpca_latente$efunctions[, k],
                                                     xout = 1:p,
                                                     rule = 2)$y
}



modele_final <- bam(Production ~ s(Temps, bs = "cc", k = 40) +
                      s(ID, by = phi_1, bs = "re") +
                      s(ID, by = phi_2, bs = "re"),
                    method = "fREML", discrete = TRUE, data = df_long_echantillon,
                    family = poisson(link = "log"))

#prédiction lissée
df_long_echantillon$Production_Lissee <- predict(modele_final,
                                                 newdata = df_long_echantillon, type = "response")
```

```r
# On isole la centrale n°1 pour comparer les données brutes et le lissage GFPCA
centrale_1 <- subset(df_long_echantillon, ID == 1)

ggplot(centrale_1, aes(x = Temps)) +
  geom_point(aes(y = Production), alpha = 0.3, color = "black", size = 1) +
  geom_line(aes(y = Production_Lissee), color = "green", linewidth = 1.2) +
  theme_minimal() +
  labs(title = "Lissage GFCPA pour la première centrale",
       x = "Temps (Intervalles de 30 min)",
       y = "Consommation (MW)")
```

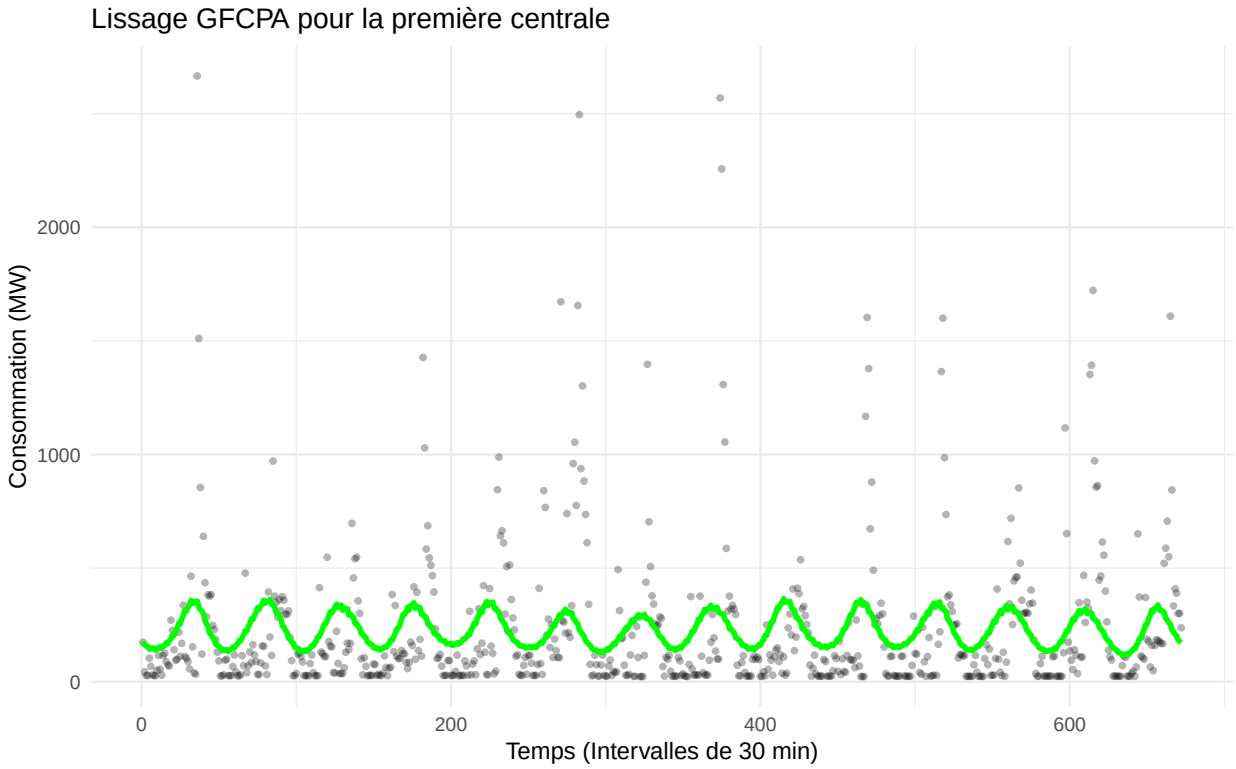


**Comparaison des deux approches :**

Les deux approches donnent des résultats cohérents : la première composante explique environ 80% de la variance totale dans les deux cas, confirmant que le niveau clobal de consommation est le principale mode de variation entre entreprises. Cependant, on peut noter quelques différences :

L'approche 1 (pca.fd) nécessite 3 composante pour atteindre plus de 90% de variance expliquée (92.1%), contre 2 composantes pour l'approche 2 (fpca.face) (91.4%). Les proportions de variance expliquée par composante sont légèrement différentes, ce qui s'explique par le fait qu'elles n'estiment pas l'opérateur de covariance de la même façon.

En termes de temps de calcul, l'approche 2 est nettement plus rapide car elle évite le lissage individuel des n = 6 275 courbes. Elle constitue donc un bon compromis entre précision et efficacité computationnelle.

# Clustering

Après réduction de dimension par Analyse en Composantes Principales Fonctionnelle (FPCA), chaque individu est représenté par un vecteur de scores $(\xi_{i1}, \xi_{i2}, \xi_{i3}, \xi_{i4})$, correspondant à sa projection sur les quatre premières fonctions propres. Ces scores résument l'essentiel de la variabilité observée entre les profils de consommation.

Nous utilisons ces coordonnées comme variables d'entrée d'un algorithme de classification non supervisée (K-means), afin d'identifier des groupes de consommateurs présentant des profils fonctionnels similaires.

L'algorithme des K-Means cherche à partitionner les individus en $C$ groupes (clusters) $G_1, \ldots, G_C$ en minimisant l'inertie intra-classe :

$$\min \sum_{c=1}^{C} \sum_{i \in G_c} \|\boldsymbol{\xi}_i - \boldsymbol{\mu}_c\|^2$$

Où $\boldsymbol{\mu}_c$ est le centre de gravité (le profil de scores moyen) du cluster $c$, et $||.||$ désigne la norme euclidienne standard dans $\mathbb{R}^K$, avec K le nombre de composantes retenues.

### Choix du nombre de clusters

Le nombre de groupes $k$ est déterminé à l'aide de deux critères complémentaires :

- La méthode du coude, qui consiste à analyser la décroissance de l'inertie intra-classe (Within-Cluster Sum of Squares) en fonction de $k$ ;
- L'indice de Silhouette, qui mesure la qualité de séparation entre les clusters en comparant la cohésion intra-classe et la séparation inter-classe.

Ces deux approches permettent d'identifier un compromis entre complexité du modèle et qualité de partition.

```r
# Extraction des scores des 3 premières harmoniques
scores_pca <- pca_res$scores[, 1:3]

# Méthode du coude
fviz_nbclust(scores_pca, kmeans, method = "wss") +
  labs(title = "Optimisation du nombre de clusters (Méthode du coude)")
```

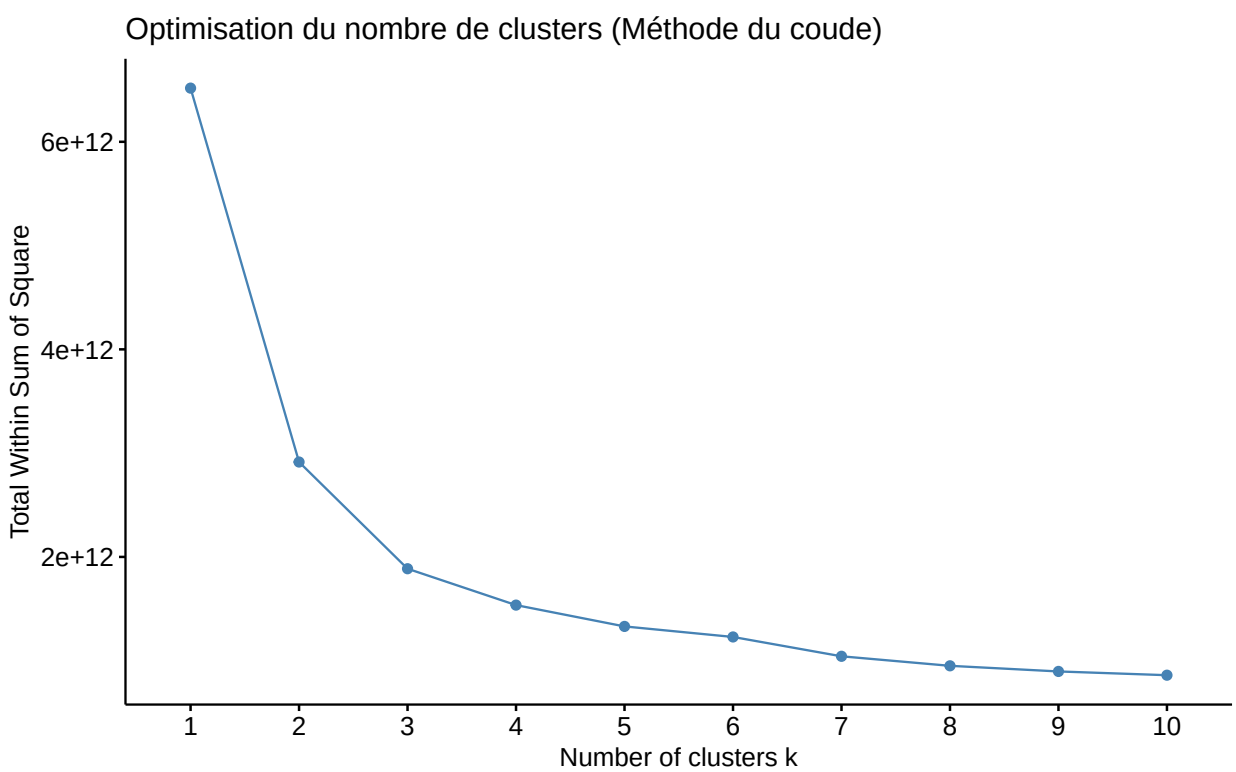

**Interprétation** La courbe présente une "cassure" très nette à k=2, suivie d'un second point d'inflexion aux alentours de k=4 ou k=5.

Décision : Nous retenons k=4 clusters. Ce choix offre un excellent compromis entre la réduction de l'erreur (inertie) et la simplicité d'interprétation des profils de consommation pour EDF.

## Application de l'algorithme K-means

```r
set.seed(123)


clusters <- 4
km_res <- kmeans(scores_pca, centers = clusters, nstart = 25)

smart_clusters <- km_res$cluster

# nombre de centrales par groupe
print(table(as.factor(smart_clusters)))
```

```
##
##    1    2    3    4
## 5831  102  314   28
```

## Visualisation et Interprétation des profils types

Afin d'interpréter les groupes obtenus par K-means, nous représentons la courbe moyenne de consommation associée à chaque cluster. Cette moyenne fonctionnelle est calculée à partir des fonctions lissées des individus appartenant au même groupe.

Cette visualisation permet d'identifier les différences structurelles entre profils et de relier la classification aux variations capturées par l'ACP fonctionnelle.

```r
# Calcul des moyennes par cluster
# On utilise les données log pour la visualisation des profils types
par(mfrow=c(2,2))
for(i in 1:4){

  indices <- which(smart_clusters == i)
  mean_cluster <- mean.fd(fd_final[indices])
  plot(mean_cluster,
       main = paste("Cluster", i, "(n =", length(indices), ")"),
       ylab = "log(1+Conso)",
       xlab = "Temps (jours)")
}
```

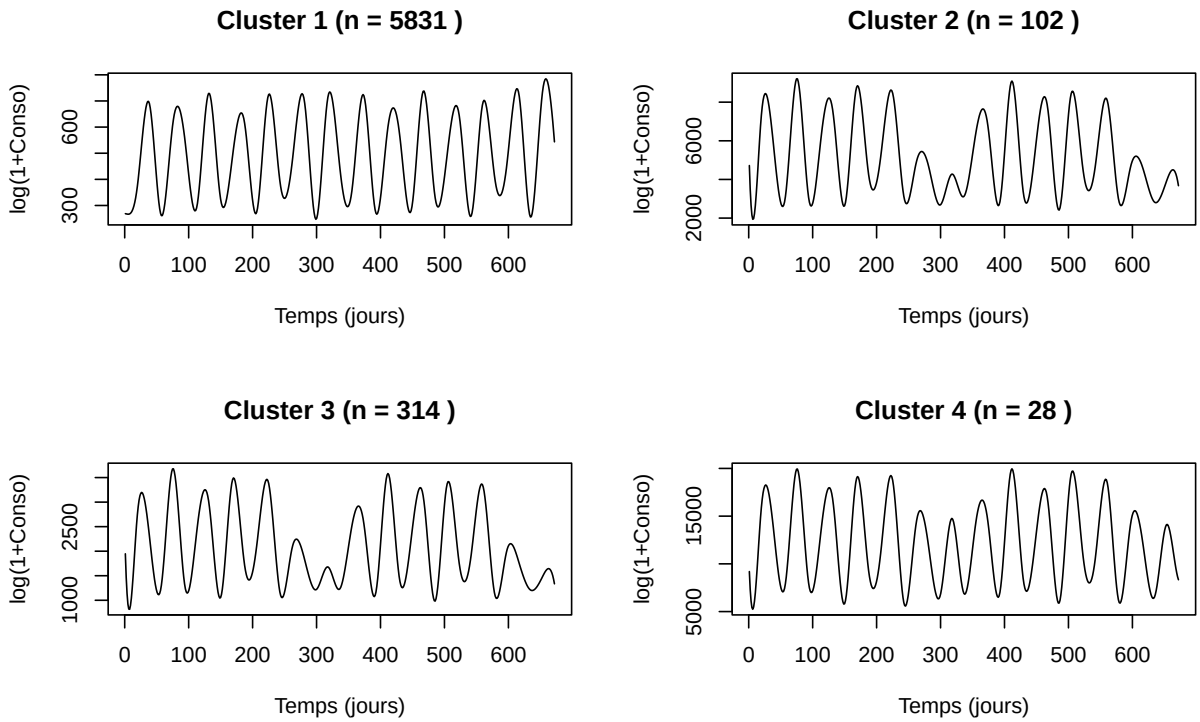


```r
table(smart_clusters)
```

```
## smart_clusters
##    1    2    3    4
## 5831  102  314   28
```

```r
km_res$tot.withinss
```

```
## [1] 1.535495e+12
```

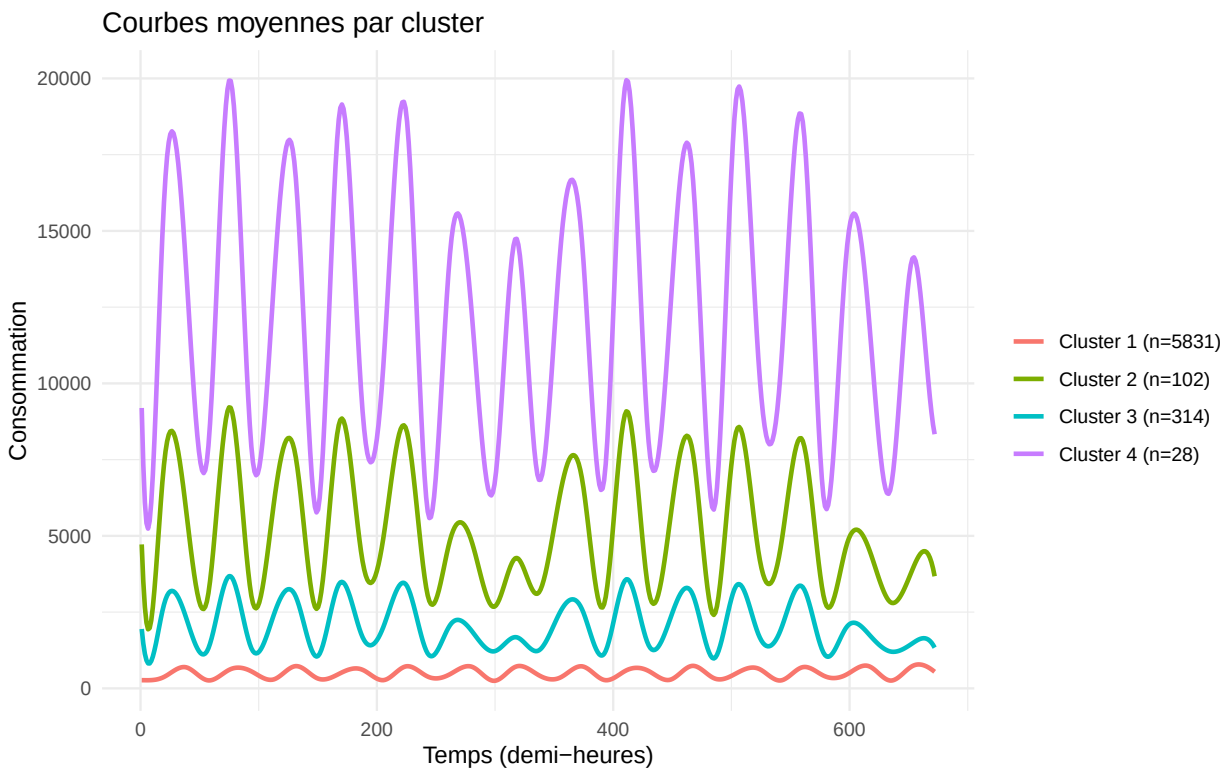


## Interprétation des profils types (centres des clusters)

### Sur données brutes

Le **Cluster 1 (n = 5831)** correspond au profil majoritaire de l'échantillon. Il présente une structure journalière régulière, avec des cycles bien définis et relativement stables sur l'ensemble de la période. Ce groupe regroupe donc les foyers présentant un comportement standard avec une consommation plutôt faible.

Le **Cluster 2 (n = 102)** rassemble des profils se distinguant par un niveau global plus élevé et une amplitude journalière marquée. Les cycles restent visibles mais présentent une variabilité plus importante au cours du temps, traduisant une intensité énergétique supérieure et des fluctuations plus prononcées.

Le **Cluster 3 (n = 314)** correspond à un profil de consommation plus modéré. Les cycles quotidiens sont bien identifiables, mais l'amplitude est globalement plus faible que dans le cluster 2. Ce groupe se situe ainsi à un niveau intermédiaire, avec une dynamique relativement stable mais moins intense.

Enfin, le **Cluster 4 (n = 28)**, très minoritaire, présente une consommation forte et une variabilité plus marquée. Les cycles journaliers demeurent visibles mais l'intensité et l'évolution temporelle diffèrent des autres groupes, suggérant des comportements spécifiques au sein de l'échantillon.

Globalement, la segmentation met principalement en évidence une différenciation selon le niveau global de consommation, tout en révélant des nuances dans l'intensité et la régularité des cycles journaliers.

### Sur données log(1+Conso) (à titre de comparaison)

Le **Cluster 1 (n = 1054)** correspond aux profils présentant le niveau global de consommation le plus faible de l'échantillon. Les cycles journaliers sont visibles mais d'amplitude modérée, avec une structure régulière sur l'ensemble des 14 jours. Ce groupe regroupe donc les foyers caractérisés par une faible intensité énergétique globale.

Le **Cluster 2 (n = 498)** rassemble les profils les plus énergivores. La courbe moyenne se situe nettement au-dessus des autres groupes et présente des pics journaliers marqués, traduisant une forte amplitude intra-journalière. Ce cluster correspond aux consommateurs présentant la plus grande variabilité et le niveau moyen le plus élevé.

Le **Cluster 3 (n = 2110)** représente un profil intermédiaire stable. Les cycles quotidiens sont bien définis et réguliers sur toute la période, avec un niveau de consommation moyen situé entre les clusters 1 et 2.

Enfin, le **Cluster 4 (n = 2629)**, le plus important numériquement, présente un niveau global proche du cluster 3 mais avec une variabilité légèrement plus marquée au cours du temps. Les amplitudes journalières sont comparables, mais la dynamique apparaît moins régulière d'un jour à l'autre, traduisant une hétérogénéité temporelle plus prononcée.

Globalement, la segmentation obtenue met principalement en évidence une différenciation selon le niveau global de consommation, avec des nuances dans l'intensité et la régularité des cycles journaliers.

## Classification Ascendante Hiérarchique (CAH) (peut être à supprimer)

Afin de confirmer la structure de groupe identifiée par la méthode du coude, nous réalisons une Classification Ascendante Hiérarchique sur les scores des 4 premières harmoniques. Nous utilisons la distance euclidienne et le critère de Ward, qui minimise la variance intra-classe à chaque étape de regroupement.

```r
#Calcul de la matrice distance
d<-dist(scores_pca, method = "euclidean")

#Application méthode  Ward
res.cah <- hclust(d, method = "ward.D2")

#Visualisation dendrogramme
plot(res.cah, labels = FALSE, main = "Dendrogramme de la CAH", sub = "", xlab = "")
rect.hclust(res.cah, k = 4, border =2:5) #Encadrer les 4 groupes
```

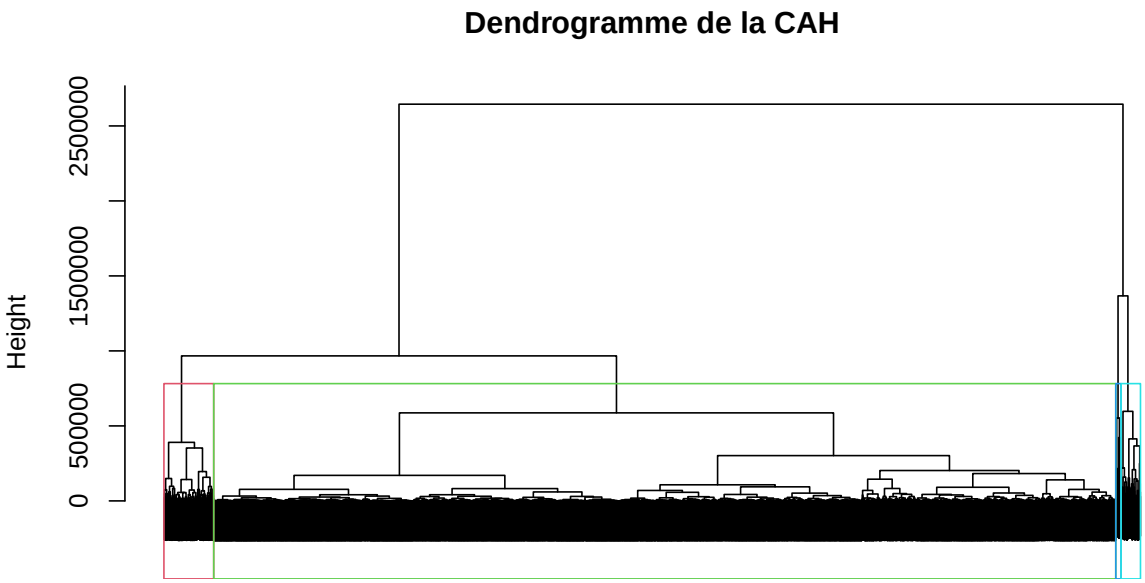


**Analyse du dendrogramme** (à refaire)

## Conclusion

(à developper plus)

Ce projet avait pour objectif d'analyser des profils de consommation électrique à partir d'enregistrements demi-horaires observés sur une période de 14 jours. L'Analyse en Composantes Principales Fonctionnelle a permis de résumer l'information contenue dans les 672 observations par individu en un nombre réduit de composantes.La première harmonique, expliquant près de 70 % de la variance totale, traduit principalement une variation d'amplitude globale autour de la moyenne fonctionnelle. Les composantes suivantes capturent des modulations temporelles plus fines mais de moindre importance.

La classification non supervisée réalisée sur les scores des quatre premières composantes a mis en évidence quatre profils distincts de consommation. La segmentation obtenue reflète principalement des différences de niveau global de consommation, avec des nuances dans la régularité et l'intensité des cycles journaliers.

Ainsi, l'approche FPCA suivie d'un clustering sur les scores constitue une méthode efficace pour synthétiser et segmenter des données de consommation énergétique massives

## Références


- Goga, C. — *Cours de Statistiques Fonctionnelles*, Université de Besançon.
- *Functional Data Analysis* with R -
- A COMPLETER